

Klasifikasi Gambar pada Land Cover dengan Menggunakan Deep Learning

(Land Cover Image Classification Using Deep Learning)

Cornelius One Setiawan, Eka Wariah, Rasyid Ammar Mujaddid, Syfa Sahbani, Viriya Lishetiyan, Vivi Alayda Yahya

¹ Prodi Geofisika, Universitas Indonesia

² Prodi Informatika, Universitas Wanita Internasional

³ Prodi Sistem Informasi, Sekolah Tinggi Teknologi Terpadu Nurul Fikri

⁴ Prodi Pendidikan Guru Sekolah Dasar, Universitas Pendidikan Indonesia, Kampus Sumedang

⁵ Prodi Pendidikan Guru Sekolah Dasar, Universitas Pendidikan Indonesia, Kampus Sumedang

⁶ Prodi Teknik Komputer, Universitas Wiralodra

*Corresponding email: corneliusonesetiawan20@gmail.com

ABSTRACT

Changes in land use or land cover are a common occurrence, both in the areas of city and regional development, as well as natural resource management. This is because many supporting facilities such as schools, offices, markets, and industry can support or facilitate community outreach towards population growth. Land change is an important issue for planners and policymakers, especially in developing countries, where law enforcement and management policies between institutions, both horizontally and vertically, are still weak. The research methodology used in this journal article is literature research. Because the accuracy value of ResNet50 is higher than the others, we finally decided on the modeling used, namely using deep learning with a Convolutional Neural Networks (CNN) model architecture, ResNet50. In this paper, we have discussed challenges in land use classification and land cover classification. For this final project, we present a dataset based on remotely sensed satellite imagery. We got this dataset from the Kaggle platform. The proposed dataset consists of 10 classes covering 13 different spectral bands for a total of 27,000 labeled and geo-referenced images. We provide benchmarks for this dataset with its spectral bands using state-of-the-art Artificial Neural Networks (CNN). For this new dataset, we analyzed the performance of 13 different spectral bands. As a result of this evaluation, the accuracy of the ResNet50 model is higher than the others, namely 97.61%.

Keywords: Remote Sensing, Land Cover, Dataset, Deep Learning, CNN

ABSTRAK

Perubahan penggunaan lahan atau tutupan lahan (Land Cover) merupakan hal yang umum terjadi, baik dalam bidang pengembangan kota dan wilayah, serta pengelolaan sumber daya alam. Hal ini dikarenakan banyaknya fasilitas-fasilitas pendukung seperti sekolah, kantor, pasar dan industri yang dapat mendukung atau memudahkan jangkauan masyarakat terhadap pertumbuhan penduduk. Perubahan lahan menjadi salah satu isu penting bagi para perencana dan penyusun kebijakan, khususnya di negara-negara berkembang, dimana masalah penegakan hukum dan kebijakan pengelolaan antar institusi baik horizontal dan vertikal masih lemah. Metodologi penelitian yang digunakan dalam artikel jurnal ini adalah penelitian literatur. Dikarenakan nilai akurasi ResNet50 lebih tinggi dari yang lain, akhirnya kita menetapkan pemodelan yang dipakai yaitu menggunakan deep learning dengan arsitektur model Convolutional Neural Networks (CNN) yaitu ResNet50. Dalam makalah ini, kami telah membahas tantangan pada klasifikasi guna lahan dan klasifikasi tutupan lahan. Untuk proyek akhir ini, kami menyajikan dataset berdasarkan citra satelit yang diindera dari jarak jauh. Dataset ini kami dapatkan dari platform Kaggle. Dataset yang diusulkan terdiri dari 10 kelas yang mencakup 13 band spektral yang berbeda dengan total 27.000 citra berlabel dan bereferensi geografis. Kami menyediakan tolok ukur untuk dataset ini dengan pita spektralnya menggunakan Jaringan Syaraf Tiruan (CNN) yang

canggih. Untuk dataset baru ini, kami menganalisis kinerja dari 13 band spektral yang berbeda. Sebagai hasil dari evaluasi ini, akurasi model ResNet50 lebih tinggi dari yang lain yaitu sebesar 97.61%.

Kata Kunci: Penginderaan Jauh, Land Cover, Dataset, Deep Learning, CNN

1. PENDAHULUAN

Perubahan penggunaan lahan atau tutupan lahan (Land Cover) ialah suatu hal yang lumrah yang sering terjadi, baik dalam sektor pengembangan di kota, wilayah, bahkan untuk mengelola sumber daya alam (SDA). Hal ini disebabkan karena banyaknya fasilitas sarana dan prasarana yang menunjang seperti gedung sekolah, kantor, pasar, dan kegiatan industri yang dapat memudahkan masyarakat untuk melakukan kelangsungan hidupnya. Perubahan lahan sering menjadi topik yang gencar dibicarakan oleh pemangku perencana dan penyusun kebijakan khususnya di negara-negara yang sedang berkembang, hal ini disebabkan karena masalah penegakan hukum dan kebijakan pengelolaan antar institusi dari segi horizontal dan vertikal masih terlalu ruai, sehingga dampak yang ditimbulkan dari perubahan guna lahan tersebut menjadi tidak teratur dan hilangnya fungsi produktivitas biologis dan keberagaman kehidupan ekosistem yang telah lama menetap dalam lahan tersebut.

Beberapa kajian studi telah dilakukan sebelumnya oleh para peneliti terkait dengan perubahan guna lahan dan tutupan lahan. Sebagai contoh, kajian tentang perubahan tutupan lahan di bagian wilayah benua Afrika selama kurun waktu sepuluh tahun (Lambin and Ehrlich, 1997); pantauan terhadap perubahan tutupan lahan di wilayah bagian Kota Bogota, Kolombia (Mendoza and Etter, 2002); pendeteksian perubahan lahan dan tutupan lahan menggunakan citra satelit di Atlanta (Yang and Lo, 2002); kajian terhadap perubahan guna lahan dan tutupan lahan di wilayah mediterania Turki (Kilic, et al., 2006); serta analisis terhadap perkembangan dan kesesuaian guna lahan di Kota Kahranmanmaras, Turki (Doygun, et al., 2008).

Selain itu, penggunaan berbagai jenis data penginderaan jauh dan analisis Sistem Informasi Geografis (SIG) telah dilakukan untuk menganalisis perubahan lahan maupun tutupan lahan, diantaranya bisa dilihat dari hasil penelitian oleh Lambin dan Ehrlich (1997) yang menggunakan sepuluh tahun data NOAA-AVHRR; penggunaan data citra landsat TM oleh Yang and Lo, 2002; kajian evaluasi dan pemantauan perubahan guna lahan menggunakan SIG dan penginderaan jauh oleh Shalaby dan Tateishi (2007), dan Xiao, et al. (2006).

Berdasarkan beberapa penelitian yang telah dilakukan didapatkan bahwa penggunaan citra satelit yang dilakukan oleh ahli geospasial dan analisis SIG dilakukan secara manual sehingga membutuhkan waktu berbulan-bulan bahkan bertahun-tahun untuk mengidentifikasi perubahan

lahan. Karena kualitas citra yang kurang memadai, data-data yang ada didalamnya tidak sepenuhnya terkini sehingga bersifat kurang akurat, interpretasi yang beragam, dan memiliki durasi analisis yang berkepanjangan, hal tersebut membuat langkah yang diambil cenderung reaktif sehingga memiliki resiko kegagalan yang tinggi dan membuat penggunaan lahan menjadi dinamis.

Artificial Intelligence (AI) merujuk pada bidang ilmu komputer yang bertujuan untuk menciptakan sistem atau mesin yang dapat melakukan tugas-tugas yang biasanya memerlukan kecerdasan manusia. Sementara itu, Machine Learning (ML) adalah subbidang AI yang fokus pada pengembangan teknik di mana sistem komputer dapat belajar dari data, mengidentifikasi pola, dan membuat keputusan tanpa adanya pemrograman eksplisit. Jadi, ML adalah satu pendekatan dalam mencapai tujuan AI secara lebih luas.


Deep learning adalah cabang dari machine learning yang menggunakan algoritma neural network untuk memodelkan dan memahami representasi data yang kompleks. Teknologi ini telah memperoleh popularitas karena kemampuannya untuk mengatasi masalah dalam berbagai bidang, seperti pengenalan wajah, deteksi objek dalam gambar, terjemahan bahasa, dan banyak lagi. Ada beberapa jenis deep learning salah satunya yaitu CNN atau Convolutional Neural Network.

Convolutional Neural Network (CNN) merupakan bagian dari deep learning. Biasanya CNN digunakan untuk bidang klasifikasi seperti pendeteksi objek, pengenalan objek berdasarkan rekaman video, pendeteksi gambar dari jarak jauh, mencari perbandingan objek dalam gambar, dan penggunaan lahan (Maulidiya et al., 2024). Jika dibandingkan dengan mesin lainnya, CNN akan secara otomatis mempelajari fitur gambar dengan sendirinya tanpa pengestraksian manual, karena itu beberapa penelitian menjadikan CNN sebagai proses pemindaian dalam pengolahan data sebelum tahap pengklasifikasian.

Adapun salah satu arsitektur model Convolutional Neural Network (CNN) yang sangat populer dalam bidang pengolahan citra, yaitu ResNet50. Ini adalah bagian dari keluarga model ResNet (Residual Networks) yang diperkenalkan oleh Microsoft Research pada tahun 2015. ResNet50 terdiri dari 50 lapisan (dengan kecuali untuk lapisan input dan output), dan menggunakan blok-blok residual untuk memungkinkan pelatihan yang lebih dalam tanpa mengalami degradasi kinerja.

2. METODOLOGI

Metodologi penelitian yang digunakan dalam artikel jurnal ini adalah penelitian literatur. Penelitian literatur adalah jenis penelitian yang dilakukan dengan mengumpulkan dan menganalisis berbagai sumber literatur terkait topik penelitian, seperti artikel jurnal, buku, dan publikasi ilmiah lainnya (Ridwan et al., 2021). Adapun proses pengumpulan datanya dilakukan menggunakan metode KDD (*Knowledge Discovery in Database*) yang bertujuan untuk menggali dan menganalisis lebih dalam mengenai jumlah data dengan ukuran yang lebih besar agar bermanfaat sebagai sumber informasi dan pengetahuan (Mar, Sholihah, Suarna, & Dwilestari, 2023). Dalam metode KDD ada beberapa urutan yang harus dilalui dimulai dari seleksi data (*Data Collection*), *reprocessing data*, modelling, dan proses evaluasi (Arifin, Enri, & Sulistiyowati, 2021).

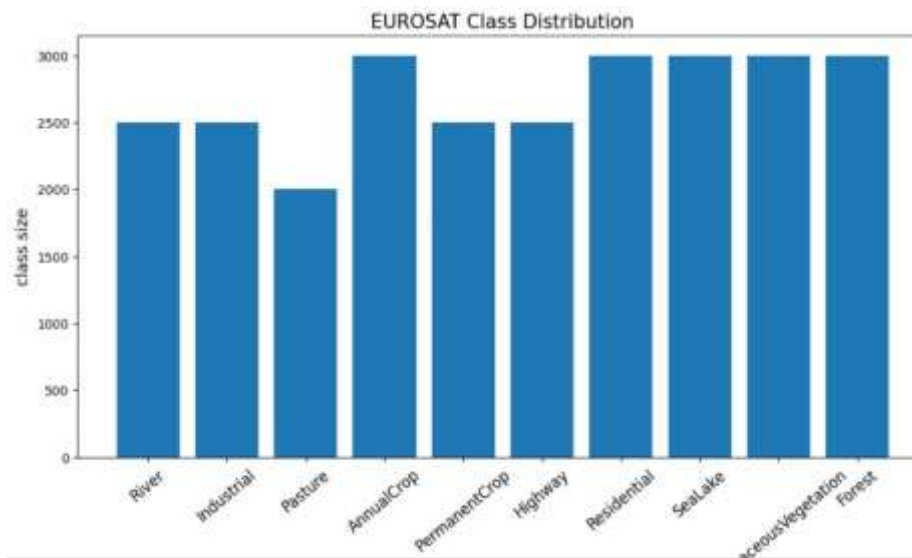


Gambar 2.1 Tahapan Metode KDD (*Knowledge Discovery in Database*)

3. HASIL DAN PEMBAHASAN

3.1. Data Collection

Proyek akhir ini melakukan pengambilan data pada platform penyedia dataset yaitu Kaggle dengan nama data EuroSAT Dataset. dataset EuroSAT terdiri dari gambar yang diambil dari satelit Sentinel-2A. pada dataset ini mencantumkan gambar permukaan bumi kedalam 10 label atau kelas *land cover* yang berbeda. Label atau kelas tersebut terdiri dari *river* (Sungai), *industrial*(industry), *pasture* (padang rumput), *annual crop* (tanaman tahunan), *permanent crop* (tanaman permanen), *highway* (jalan raya), *residential* (perumahan), *sea lake* (danau laut), *herbaceous vegetation* (vegetasi herba), dan *forest* (hutan). Untuk jumlah populasi datanya pada dataset EuroSAT terdiri dari 27.000 gambar yang tersebar di 10 kelas. Berikut ini merupakan data visualisasi dari data set tersebut.



Gambar 1. Visualisasi Data

Pada data visualisasi tersebut dapat diketahui bahwa tiap kelasnya terdiri dari kelas river, industrial, pasture, annual crop, permanent crop, highway, residential, sea lake, herbaceous vegetation, dan forest. Berikut contoh gambar data dari masing-masing kelas:



*Gambar 2.1
River*



*Gambar 3.2
Industrial*



*Gambar 4.3
Pasture*



*Gambar 5.4
Annual Crop*



*Gambar 6.5
Permanent Crop*



*Gambar 7.6
Highway*



*Gambar 8.7
Residential*



*Gambar 9.8
Sea Lake*



*Gambar 10.9
Herbaceous Vegetation*



*Gambar 11.10
Forest*

Berdasarkan pratinjau gambar data diatas dapat dilihat beberapa persamaan dan perbedaan antar data pada kelas. Lingkungan perkotaan seperti highway, residential, dan industrial berisi struktur dan beberapa jalan raya. Annual crop dan permanent keduanya memiliki land cover pertanian dengan garis lurus yang membatasi lahan tanaman yang berbeda. Lalu yang terakhir ada herbaceous vegetation, pasture dan forest yang memiliki land cover yang alami. Sungai juga dikategorikan sebagai land cover alami namun mungkin lebih mudah dibedakan dari kelas land cover alami lainnya.

3.2.Preprocessing Data

Data yang sudah di dapatkan kemudian akan digunakan untuk mengevaluasi performa model. Sebelum lanjut ke tahap pemodelan, data tersebut akan dievaluasi lagi untuk dapat mempertahankan proporsi kelas dan dapat dievaluasi kedalam pemodelan. Pada tahap preprocessing data ini menggunakan metode stratified shuffle-split yaitu Scikit-learn yaitu

data tersebut akan dibagi 2 kedalam 2 folder Dimana 80% akan disimpan pada data training dan 20% nya akan disimpan pada data testing.

```
1 import re
2 from sklearn.model_selection import StratifiedShuffleSplit
3 from keras.preprocessing.image import ImageDataGenerator
4
5 TRAIN_DIR = '../working/training/'
6 TEST_DIR = '../working/testing/'
7 BATCH_SIZE = 64
8 NUM_CLASSES=len(LABELS)
9 INPUT_SHAPE = (64, 64, 3)
10 CLASS_MODE = 'categorical'
11
12 # create training and testing directories
13 for path in (TRAIN_DIR, TEST_DIR):
14     if not os.path.exists(path):
15         os.mkdir(path)
16
17 # create class label subdirectories in train and test
18 for i in LABELS:
19
20     if not os.path.exists(os.path.join(TRAIN_DIR, i)):
21         os.mkdir(os.path.join(TRAIN_DIR, i))
22
23     if not os.path.exists(os.path.join(TEST_DIR, i)):
24         os.mkdir(os.path.join(TEST_DIR, i))
```

Gambar 2. Metode scikit-learn

```
1 data = {}
2
3 for i in LABELS:
4     img_list = os.listdir(DATASET+"/"+i)
5     data.update({os.path.join(DATASET, i, img): 1})
6
7 X = pd.Series(list(data.keys()))
8 y = pd.Series(list(data.values()))
9
10 split = StratifiedShuffleSplit(n_splits=1, test_size=0.2, random_state=0)
11
12 # split the list of image paths
13 for train_idx, test_idx in split.split(X, y):
14
15     train_paths = X[train_idx]
16     test_paths = X[test_idx]
17
18 # define a new path for each image depending on training or testing
19 new_train_paths = [re.sub(r'\./input/278P', '../working/training', i) for i in train_paths]
20 new_test_paths = [re.sub(r'\./input/278P', '../working/testing', i) for i in test_paths]
21
22 train_path_map = dict(zip(train_paths, new_train_paths))
23 test_path_map = dict(zip(test_paths, new_test_paths))
24
25 # move the files
26 print("moving training files..")
27 for i in tqdm(train_path_map):
28     if not os.path.exists(i[1]):
29         if not os.path.exists(re.sub("training", "testing", i[1])):
30             copy(i[0], i[1])
31
32 print("moving testing files..")
33 for i in tqdm(test_path_map):
34     if not os.path.exists(i[1]):
35         if not os.path.exists(re.sub("training", "testing", i[1])):
36             copy(i[0], i[1])
```

Gambar 3. Proses memindahkan data

Ketika dijalankan maka hasilnya sebagai berikut:

```
moving training files..  
100%|██████████| 21600/21600 [00:05<00:00, 4267.64it/s]  
moving testing files..  
100%|██████████| 5400/5400 [00:00<00:00, 8543.22it/s]
```

Gambar 4. Output dari pemindahan data

Dan data-data tersebut dimuatkan ke dalam model keras menggunakan kelas ImageDataGenerator. Setelah itu dibuatlah beberapa augmentasi gambar menggunakan generator.

```
1  train_gen = ImageDataGenerator(  
2      rescale=1./255,  
3      rotation_range=60,  
4      width_shift_range=0.2,  
5      height_shift_range=0.2,  
6      shear_range=0.2,  
7      zoom_range=0.2,  
8      horizontal_flip=True,  
9      vertical_flip = True  
10 # validation_split=0.2  
11 )  
12  
13 train_generator = train_gen.flow_from_directory(  
14     directory=TRAIN_DIR,  
15     target_size=(64, 64),  
16     batch_size=BATCH_SIZE,  
17     class_mode=CLASS_MODE,  
18     #subset='training',  
19     color_mode='rgb',  
20     shuffle=True,  
21     seed=69  
22 )  
23  
24 test_gen = ImageDataGenerator(  
25     rescale=1./255,  
26 )  
27  
28 test_generator = test_gen.flow_from_directory(  
29     directory=TEST_DIR,  
30     target_size=(64, 64),  
31     batch_size=BATCH_SIZE,  
32     class_mode=CLASS_MODE,  
33     color_mode='rgb',  
34     shuffle=False,  
35     seed=69  
36 )
```

Gambar 5. Kode program untuk augmentasi Gambar menggunakan ImageDataGenerator

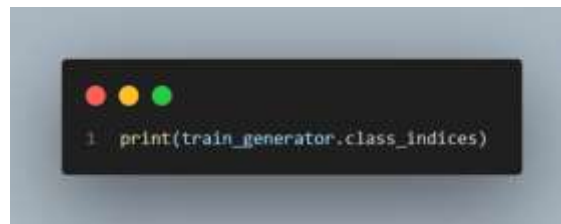
Ketika dijalankan maka hasilnya sebagai berikut:

```
Found 21600 images belonging to 10 classes.  
Found 5400 images belonging to 10 classes.
```


Gambar 6. Hasil output dari augmentasi gambar

Hal tersebut digunakan untuk menunjukkan subset data training yang akan digunakan sebagai data validasi selama pelatihan dan pemodelan. Dimana hasilnya menunjukkan bahwa terdapat data training yang terdiri dari 21600 gambar yang terbagi dalam 10 kelas, kemudian ada data testing yang terdiri dari 5400 gambar yang terbagi ke dalam 10 kelas.

Untuk menampilkan dan mencetak indeks yang terdapat pada kelas bisa menggunakan kode berikut:



Gambar 7. Kode program untuk mencetak indeks pada *class*

Ketika kode dijalankan maka hasilnya akan sebagai berikut:

```
{'AnnualCrop': 0, 'Forest': 1, 'HerbaceousVegetation': 2, 'Highway': 3, 'Industrial': 4, 'Pasture': 5, 'PermanentCrop': 6, 'Residential': 7, 'River': 8, 'SeaLake': 9}
```

Gambar 8. Tampilan hasil indeks dari setiap *class*

Dari hasil yang ditunjukkan kita dapat melihat indeks yang terdapat pada setiap kelas misalnya pada kelas AnnualCorp yang mempunyai indeks 0, kemudian pada kelas Forest memiliki indeks 1 dan seterusnya. Kemudian data yang sudah melalui tahap reprocessing data akan di simpan untuk kebutuhan pada pemodelan.



Gambar 9. Kode program untuk menyimpan data *class_indices*

3.3. Modelling

Machine learning dan deep learning biasa digunakan sebagai pemodelan AI untuk image classification, dimana pemodelan AI ini merupakan proses untuk mengembangkan model komputasional yang dapat mengidentifikasi dan mengklasifikasikan objek atau kelas pada gambar berdasarkan pembelajaran dari data gambar yang telah diberikan. Tujuan dari image classification adalah untuk mengenali pola visual dalam gambar dan mengaitkan gambar tersebut dengan label kategori atau kelas tertentu.

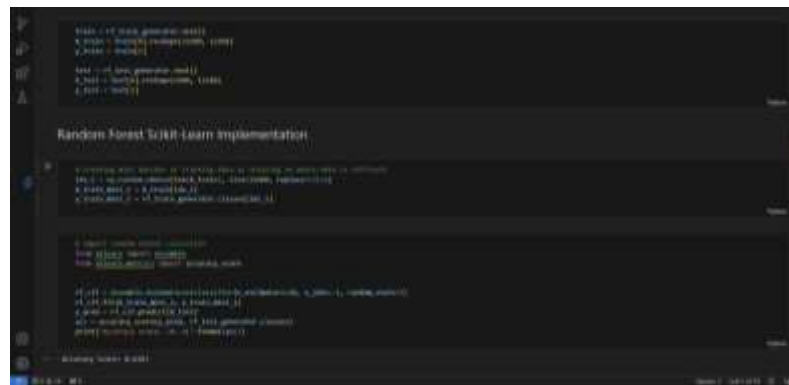
Dataset yang didapat merupakan dataset yang berisi tentang gambar land cover yang diambil oleh satellite sentinel-2A yang dapat digunakan untuk pemodelan AI dengan

menggunakan model salah satunya yaitu model CNN (Convolutional Neural Network) dan beberapa model lainnya yang termasuk kedalam model machine learning dan deep learning.

Pertama, kita akan melihat performa model pembelajaran Machine Learning dengan memasukkan seluruh piksel gambar ke dalamnya ($64 \times 64 \times 3 = 12288$). Dari pembagian 80-20 pada dataset 27000 sampel, data pelatihan berukuran 21600 dan data pengujian berukuran 5400.

Dalam hal ini kami mencoba beberapa model yaitu model Forest Random dari Machine Learning dan 2 model CNN yaitu ResNet50 dan VGG16 dari deep learning.

- Model Forest Random dari Machine Learning



```
from sklearn.metrics import accuracy_score
from sklearn.model_selection import train_test_split
from sklearn.ensemble import RandomForestClassifier

# Load data
X = load_data()
y = load_labels()

# Split data into training and testing sets
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)

# Create a Random Forest classifier
rfc = RandomForestClassifier(n_estimators=100, random_state=42)

# Train the classifier
rfc.fit(X_train, y_train)

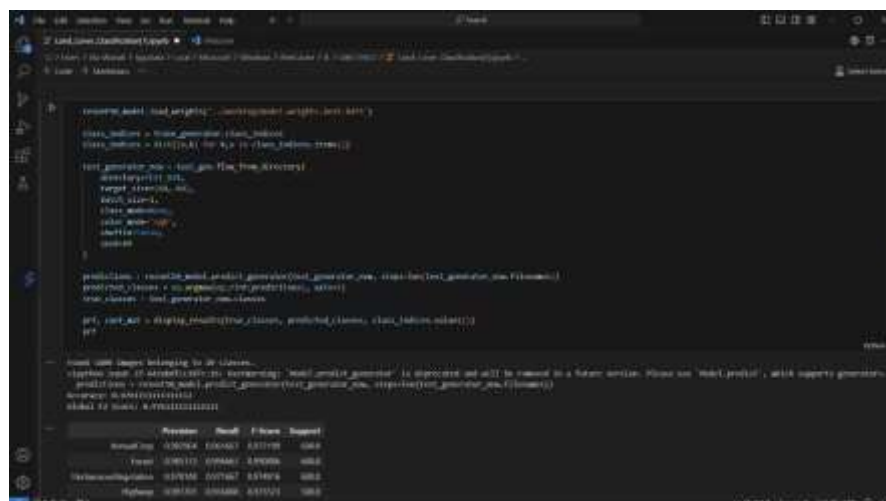
# Predict on the test set
y_pred = rfc.predict(X_test)

# Calculate accuracy
accuracy = accuracy_score(y_test, y_pred)
print('Accuracy: %.4f' % accuracy)
```

Gambar 10. Coding Implementasi model Scikit-Learn

Gambar diatas merupakan coding atau kode dari machine learning agar dapat digunakan kedalam model Random Forest Scikit-Learn Implementation dengan memunculkan hasil atau skor akurasi yaitu 0.6163 atau 61.63%

- ResNet50



```
from keras.preprocessing.image import ImageDataGenerator
from keras.models import Sequential
from keras.layers import Conv2D, MaxPooling2D, Flatten, Dense, Dropout
from keras.callbacks import EarlyStopping

# Load data
train_data_dir = 'train_data_dir'
validation_data_dir = 'validation_data_dir'

# Create data generators
train_generator = ImageDataGenerator(rescale=1./255, validation_split=0.2)
validation_generator = ImageDataGenerator(rescale=1./255)

# Build the ResNet50 model
model = Sequential([
    Conv2D(64, (3, 3), input_shape=(224, 224, 3), activation='relu'),
    MaxPooling2D(pool_size=(2, 2)),
    Conv2D(128, (3, 3), activation='relu'),
    MaxPooling2D(pool_size=(2, 2)),
    Conv2D(256, (3, 3), activation='relu'),
    MaxPooling2D(pool_size=(2, 2)),
    Conv2D(512, (3, 3), activation='relu'),
    MaxPooling2D(pool_size=(2, 2)),
    Conv2D(1024, (3, 3), activation='relu'),
    MaxPooling2D(pool_size=(2, 2)),
    Flatten(),
    Dense(1000, activation='softmax')
])

# Compile the model
model.compile(optimizer='adam', loss='categorical_crossentropy', metrics=['accuracy'])

# Train the model
early_stopping = EarlyStopping(monitor='val_loss', patience=10)
model.fit_generator(train_generator.flow(train_data_dir, train_data_dir),
                    validation_data=validation_generator.flow(validation_data_dir, validation_data_dir),
                    epochs=100,
                    callbacks=[early_stopping])

# Evaluate the model
y_pred = model.predict(validation_generator.flow(validation_data_dir, validation_data_dir))
y_true = validation_generator.classes

# Print the classification report
from sklearn.metrics import classification_report
print(classification_report(y_true, y_pred))
```

Gambar 11. Coding Implementasi model ResNet50

Gambar 13. Training and Validation Accuracy dan Training and Validation Loss

Dari gambar grafik diatas dapat disimpulkan:

1. Berdasarkan grafik training and validation accuracy, garis akurasi dan loss memiliki tren yang sama, yaitu meningkat seiring bertambahnya epoch. Hal ini menunjukkan bahwa model belajar dan menjadi lebih akurat seiring bertambahnya epoch.
2. Berdasarkan grafik training and validation loss, garis akurasi dan loss memiliki tren yang sama, yaitu menurun seiring bertambahnya epoch. Hal ini menunjukkan bahwa model belajar dan menjadi lebih akurat seiring bertambahnya epoch.

4. SIMPULAN

Dalam makalah ini, kami telah membahas tantangan pada klasifikasi guna lahan dan klasifikasi tutupan lahan. Untuk proyek akhir ini, kami menyajikan dataset berdasarkan citra satelit yang diindera dari jarak jauh. Dataset ini kami dapatkan dari platform Kaggle. Dataset yang diusulkan terdiri dari 10 kelas yang mencakup 13 band spektral yang berbeda dengan total 27.000 citra berlabel dan bereferensi geografis. Kami menyediakan tolok ukur untuk dataset ini dengan pita spektralnya menggunakan Jaringan Syaraf Tiruan (CNN) yang canggih. Untuk dataset baru ini, kami menganalisis kinerja dari 13 band spektral yang berbeda. Sebagai hasil dari evaluasi ini, akurasi model ResNet50 lebih tinggi dari yang lain yaitu sebesar 97.61%. Secara keseluruhan, citra satelit Sentinel-2 yang tersedia secara gratis menawarkan berbagai macam aplikasi yang memungkinkan. Proyek akhir ini memanfaatkan sejumlah besar data satelit yang tersedia dalam pembelajaran mesin yang memungkinkan untuk memantau permukaan bumi dalam skala besar. Kumpulan data yang diusulkan dapat dimanfaatkan untuk berbagai aplikasi pengamatan Bumi di dunia nyata. Aplikasi yang memungkinkan adalah deteksi perubahan guna lahan dan deteksi perubahan tutupan lahan atau peningkatan peta geografis.

DAFTAR PUSTAKA

- Arifin, N., Enri, U., & Sulistiyowati, N. (2021). Penerapan Algoritma Support Vector Machine (SVM) dengan TF-IDF N-Gram untuk Text Classification. *STRING (Satuan Tulisan Riset Dan Inovasi Teknologi)*, 6(2), 129. doi: 10.30998/string.v6i2.10133
- Guntara, R. G. (2023). Pemanfaatan Komputer Vision pada E-Commerce. *Rangga Gelar Guntara) Madani: Jurnal Ilmiah Multidisiplin*, 1(3), 2302–6219. doi: 10.5281/zenodo.7881002
- Hattiya, T., Dittakan, K., & Musikasuwan, S. (2021). Diabetic Retinopathy Detection using Convolutional Neural Network: A Comparative Study on Different Architectures. *Engineering Access*, 7(1), 50–60. doi: 10.14456/mijet.2021.8
- Mar, O., Sholihah, atun, Suarna, N., & Dwilestari, G. (2023). Implementasi Metode K-means Clustering Untuk Menganalisa Penerima Bantuan di Desa Palasah. *Jurnal Informatika Dan Teknologi Informasi*, 1(2), 111–117. doi: 10.56854/jt.v1i2.121
- Maulidiya, E., Fatichah, C., Suciati, N., Maulidiya, E., Fatichah, C., Suciati, N., & Baskoro, F. (2024). *Klasifikasi tutupan lahan uav menggunakan convolutional neural network feature map dengan kombinasi machine learning*. 45–55.
- Murphy, K. P. (2012). Machine Learning - A Probabilistic Perspective - Table-of-Contents. *The MIT Press*, 1049.
- Russell, S. J., Norvig, P., Davis, E., Edwards, D. D., Hay, N. J., Malik, J. M., & Thrun, S. (n.d.). *Artificial Intelligence*.
- Wijaya, N. (2015). Deteksi Perubahan Penggunaan Lahan Dengan Citra Landsat Dan Sistem Informasi Geografis: Studi Kasus Di Wilayah Metropolitan Bandung, Indonesia. *Geoplanning: Journal of Geomatics and Planning*, 2(2), 82–92. doi: 10.14710/geoplanning.2.2.82-92

- Burhanudin Zuhri, N. H. (2023). *Aplikasi Rekrutmen Karyawan Menggunakan Artificial Neural Network dan Flask*. Retrieved from <http://www.sisfotenika.stmikpontianak.ac.id>
- Emhandyksa, M. (2023, Desember). *Pengembangan Deep Learning untuk Sistem Deteksi Dini Komplikasi Kaki Diabetik Menggunakan Citra Termogram*. Retrieved from <https://jtiik.ub.ac.id>
- Hidayatulloh, S. (2023, February 15). *PENGUNAAN OTIMASI ATRIBUT DALAM PENINGKATAN AKURASI PREDIKSI DEEP LEARNING PADA BIKE SHARING DEMAND*. Retrieved from <https://ejournal.unma.ac.id>
- Jibhakate, P., Gole, S., Yeskar, P., & Rangwani, N. (2022). *Early Glaucoma Detection Using Machine Learning Algorithms of VGG-16 and Resnet-50*. Retrieved from <https://ieeexplore.ieee.org>
- Mascarenhas, S., & Agarwal, M. (2021). *A comparison between VGG16, VGG19 and ResNet50 architecture frameworks for Image Classification*. Retrieved from <https://ieeexplore.ieee.org>
- Rezende, E., Ruppert, G., Carvalho, T., Ramos, F., & Geus, P. d. (2017). *Malicious Software Classification Using Transfer Learning of ResNet-50 Deep Neural Network*. Retrieved from <https://ieeexplore.ieee.org>
- Wahyu Wijaya Kusuma, R. R. (2022, April). *Analisis Perbandingan Model CNN VGG16 dan DenseNet121 Menggunakan Kerangka Kerja TensorFlow untuk Deteksi Jenis Hewan*. Retrieved from <https://ejournal3.undip.ac.id>